File Blocking Algorithm

1. 算法简析

分布式文件系统中,因文件丢失易导致文件无法恢复的问题。相较于传统全备份 方式,本算法采用文件编码方式,以较低的备份冗余度、一定的计算消耗,来实现动 态、高容错性的文件恢复。

2. 算法基础

2.1 编码恢复数学原理【网络编码方式】

◆ 编码过程: A 为编码矩阵 (目前以 5*3 为例); B 为数据块; C 为编码后的数据

$$\begin{bmatrix} A_{11} & A_{12} & A_{13} \\ A_{21} & A_{22} & A_{23} \\ A_{31} & A_{32} & A_{33} \\ A_{41} & A_{42} & A_{43} \\ A_{51} & A_{52} & A_{53} \end{bmatrix} \otimes \begin{bmatrix} B_{11} & B_{12} & B_{13} \\ B_{21} & B_{22} & B_{23} \\ B_{31} & B_{32} & B_{33} \end{bmatrix} = \begin{bmatrix} C_{11} & C_{12} & C_{13} \\ C_{21} & C_{22} & C_{23} \\ C_{31} & C_{32} & C_{33} \\ C_{41} & C_{42} & C_{43} \\ C_{51} & C_{52} & C_{53} \end{bmatrix}$$

◆ 译码过程: (假设只取回 C_{1i} 、 C_{3i} 、 C_{5i} 三个编码数据块)。 **只要 A 矩阵满秩,**则一定可以得到唯一解,即正确恢复原数据B。

$$\begin{bmatrix} B_{11} & B_{12} & B_{13} \\ B_{21} & B_{22} & B_{23} \\ B_{31} & B_{32} & B_{33} \end{bmatrix} = \begin{bmatrix} A_{11} & A_{12} & A_{13} \\ A_{31} & A_{32} & A_{33} \\ A_{51} & A_{52} & A_{53} \end{bmatrix}^{-1} \otimes \begin{bmatrix} C_{11} & C_{12} & C_{13} \\ C_{31} & C_{32} & C_{33} \\ C_{51} & C_{52} & C_{53} \end{bmatrix}$$

3. 有限域

3.1 群、环、域

一组元素的集合,以及在集合上的四则运算,构成一个域。其中加法和乘法必须满足交换、结合和分配的规律。加法和乘法具有封闭性,即加法和乘法结果仍然是域中的元素。

域中必须有加法单位元和乘法单位元,且每一个元素都有对应的加法逆元和乘法逆元。但不要求域中的 0 有乘法逆元。

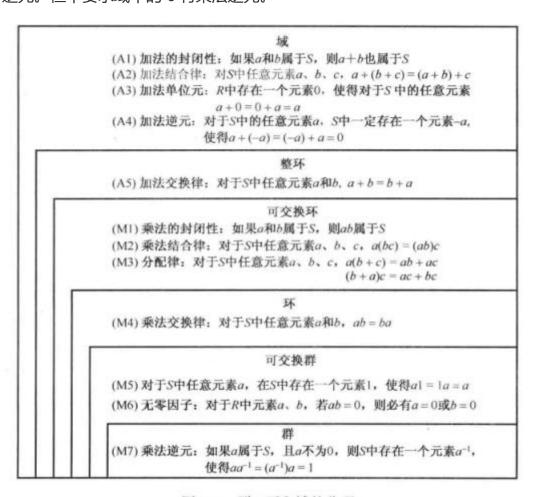


图 4.2 群、环和域的公理

3.2 有限域

有理数 Q、复数 C,以及其它的一些数域都满足这些条件,它们都是域。不过这些域都是无限域,因为信息科学领域里用到的域,都是有限域。

在数学上,有限域(finite field)是包含有限个数的域,有限域是进行加减乘除运算都有定于,并且满足特定规则的集合。有限域的乘法群是循环群,即若 F 是有限群,则存在 $\alpha \in F$,使得 $F^* = \{x \in F | x \neq 0\} = \langle \overline{o} \rangle$ 。

因为在数据传输过程,如果选择实数域的矩阵运算,数据范围会很大,网络传输 不方便,因此一般采用有限域的矩阵运算。

有限域 GF(p),其中 p 为素数。GF(p)里面的加法和乘法与一般的加法和乘法差不多,区别是结果需要 mod p,以保证结果都是域中的元素。GF(p)的加法和乘法单位元分别是 0 和 1。

GF(p)加法是(a+b) mod p,乘法是(a*b)mod p。对于域中的乘法,当 p 为素数时,才能保证集合中的所有的元素都有乘法逆元(0 除外)。即对于域中的任一个元素 a,总能在域中找到另外一个元素 b,使得 a*b mod p 等于 1。

说明:假如 p 等于 10,其乘法单位元为 1。对于元素 2,找不到一个数 a,使得 2*a mod 10 等于 1,即 2没有乘法逆元。这时,在域上就不能进行除 2运算。

3.2.1 单位元、逆元

单位元

通常使用 e 来表示单位元。单位元和其他元素结合时,并不会改变那些元素。 对于二元运算*,若 a*e=a, e 称为右单位元;若 e*a=a, e 称为左单位元,若 a*e=e*a=a,则 e 称为单位元。

逆元

对于二元运算*, 若 a*b=e, 则 a 称为 b 的左逆元素, b 称为 a 的右逆元素。若 a*b=b*a=e, 则称 a 为 b 的逆元, b 为 a 的逆元。

3.3 有限域 GF(q^m)

一类最简单的有限域: Z_p , 它的意思是整数集合 Z 模 p 得到的同余类,其中 p 为素数。简单点说,就是包含 p 个数的集合 $\{0,1,2,\ldots,p-1\}$,只不过这些数进行加法和乘法运算时需要模 p,保证算完了还在这个集合里面。

注意这里p一定要是素数,如果是合数n, Z_n 就只是一类环,不是域了

其次,为了得到更多的有限域,需要一个定理做支撑:

◆ 定理7 多项式模首一多项式p(x)环成为域的充分 必要条件是p(x) 为素多项式。

按照这个定理,**给定一个已知的有限域** GF(q), 找到这个有限域上的一个 m 次素多项式,我们就能构造出一个新的有限域,这个有限域包含的元素个数为 qⁿm,也就是得到了一个 GF(qⁿ)。根据第一条,我们已经有了一类有限域: Zp,其中 p 为素数。根据第二条,为了得到更多的有限域,我们需要寻找有限域 Zp 上的素多项式。

按照定义,素多项式是首项系数为1的不可约多项式,那么只要找到不可约多项式,除以首项系数,就得到素多项式了。

3.4 多项式

3.4.1 素多项式/本原多项式

本原多项式 (primitive polynomial)是一种特殊的不可约多项式。当一个域上的本原多项式确定了,这个域上的运算也就确定了。通过将域中的元素化为多项式形式,可以将域上的乘法运算转化为普通的多项式乘法再模本原多项式。

部分 GF (2^w) 域经常使用的本原多项式如下:

$$w = 4:$$
 $x^4 + x + 1$
 $w = 8:$ $x^8 + x^4 + x^3 + x^2 + 1$
 $w = 16:$ $x^{16} + x^{12} + x^3 + x + 1$
 $w = 32:$ $x^{32} + x^{22} + x^2 + x + 1$
 $w = 64:$ $x^{64} + x^4 + x^3 + x + 1$

3.4.2 素多项式运算

指数小于 3 的多项式有 8 个,分别是 0, 1, x, x+1, x^2, x^2+1, x^2+x, x^2+x+1。对于 GF(2^3)来说,其中一个素多项式为 x^3+x+1。上面 8 个多项式进行四则运算后 mod (x^3+x+1)的结果都是 8 个之中的某一个,可以证明这是一个域,所以每一个多项式都是有加法和乘法逆元的(0 除外)。注意,这些逆元都是和素多项式相关的,同一个多项式,取不同的素多项式,就有不同的逆元多项式。

对于 GF(2⁸),其中一个素多项式为 $x^8 + x^4 + x^3 + x + 1$ 。对应地,小于 8 次的多项式有 256 个。

由素多项式得到的域,其加法单位元都是0,乘法单位元是1。

前面讲到了对素多项式取模,然后可以得到一个域。但这和最初的目的有什么关系吗?多项式和 0, 1, ……, 255 没有什么关系。确实是没有什么关系,但多项式的系数确可以组成 0, 1, 2, ……255 这些数。回到刚才的 GF(2³),对应的 8 个多项式,其系数刚好就是 000,001, 010, 011, 100, 101, 110, 111。这不正是 0 到 7 这 8 个数的二进制形式吗?也就是说,它们有一一对应映射的关系。**多项式对应一个值**,我们可以称这个值为多项式值。

对于 GF(2³),取素多项式为 x³ + x+1,那么多项式 x²+x 的乘法逆元就是 x+1。系数对应的二进制分别为 110 和 011。此时,我们就认为对应的十进制数 6 和 3 互为逆元。即使 mod 8 不能构成一个域,但通过上面的对应映射,0 到 7 这 8 个数一样有对应逆元了(为了顺口,说成 0 到 7。实际 0 是没有乘法逆元的)。同样,对于 GF(2⁸)也是一样的。所以 0 到 255,这 256 个数都可以通过这样的方式得到乘法逆元(同样,0 是没有乘法逆元的)。

3.4.3 加法/减法【亦或】

合并同类项时,系数们进行异或操作,不是平常的加法操作。比如 $x^4 + x^4$ 等于 $0*x^4$ 。因为两个系数都为 1, 进行异或后等于 0。

无所谓的减法(减法就等于加法),或者负系数。所以, $x^4 - x^4$ 就等于 $x^4 + x^4$ 。 $-x^3$ 就是 x^3

3.4.4 乘法/除法

(F(x)*G(x)) mod m(x) : m(x) 为本原多项式

看一些例子吧。对于 $f(x) = x^6 + x^4 + x^2 + x + 1$ 。 $g(x) = x^7 + x + 1$ 。

那么 $f(x) + g(x) = x^7 + x^6 + x^4 + x^2 + (1+1)x + (1+1)1 = x^7 + x^6 + x^4 + x^2$ 。 f(x) - g(x)等于f(x) + g(x)。

 $f(x) * g(x) = (x^13 + x^11 + x^9 + x^8 + x^7) + (x^7 + x^5 + x^3 + x^2 + x) + (x^6 + x^4 + x^2 + x + 1) = x^13 + x^11 + x^9 + x^8 + x^6 + x^5 + x^4 + x^3 + 1$

下图是除法,除法得到的余数,也就是mod操作的结果。

$$x^{8} + x^{4} + x^{3} + x + 1) x^{10} + x^{9} + x^{2} + x + 1$$

$$x^{10} + x^{6} + x^{5} + x^{3} + x^{2}$$

$$x^{9} + x^{6} + x^{5} + x^{3} + x + 1$$

$$x^{9} + x^{5} + x^{4} + x^{2} + x$$

$$x^{6} + x^{4} + x^{3} + x^{2} + 1$$

3.5 查表

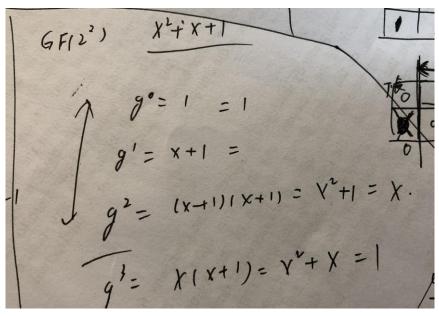
3.5.1 单位元

如果元素 g 满足下面的条件,我们就称 g 为生成元: 对于集合中的任何的一个元素,都可以通过元素 g 的幂 g^k 得到。并定义 g^0=e,假设 h 为 g 的逆元,那么还定义 g^(-k)=h^k。比如,整数集合,都可以由生成元 1 得到。 $2=1+1=1^2$ 、 $3=1^3=1+1+1$ 、……。负数可以通过幂取负数得到。

对于 $g^k = a$,有正过程和逆过程。知道 k 求 a 是正过程,知道了 a 反过来求 k 是逆过程。同样,假设有 $g^n = a$ 和 $g^m = b$ 。现在需要求 a^b ,那么就有 $a^b = g^n$ $g^m = g^n = g^n$,我们只需要:根据 a 和 b,分别求得 a 和 a 。然后直接计算 a a a 即可。这里,构造两个表,正表和反表。正表是知道了指数,求值。反表是知道了值,求指数。接下来要做的就是构造这两个表。为了做除法运算,还要构造逆元表。

假设 g 是域 $GF(2^w)$ 上生成元,那么集合 $\{g0, g1, \dots, g(2^w-1)\}$ 包含了域 $GF(2^w)$ 上所有非零元素。**在域 GF(2^w)中 2 总是生成元**。

 $GF(2^{k})$ 是一个有限域,就是元素个数是有限的,但指数 k 是可以无穷的。所以必然存在循环。这个循环的周期是 2^{k} (g 不能生成多项式 0)。所以当 k 大于等于 2^{k} g^{k} g^{k} g^{k}



3.5.2 正表反表构建

对于正表,生成元的指数,取 0 到 254 即可,对应地生成 255 个不同的多项式,多项式的取值范围为 1 到 255。

对于正表,只需依次计算 g^0 、 g^1 、 g^2 , ……, g^2 4 即可。对于 $GF(2^8)$,素多项式 $m(x) = x^8 + x^4 + x^3 + x + 1$,对应的生成元 g(x) = x + 1。

反表和正表是对应的,所以反表中元素的个数也是255个。正表中,生成元g的

指数 k 的取值范围为 0 到 254。多项式值 g^k 的取值范围为 1 到 255。所以在反表中,下标的取值范围为 1 到 255,元素值的取值范围为 0 到 254。

对于逆元表,先看逆元的定义。若 a 和 b 互为逆元,则有 a*b = e。用生成元表示为: $g^n* g^m = e = 1$ 。又因为 $e = g^0 = g^255$ (循环,回头了)。所以 $g^k* g^255-k$ = $g^k* g^2 = g^k* g^2 = g^2$

```
int inverse_table[256];

for(i = 1; i < 256; ++i)//0没有逆元,所以从1开始
{
    int k = arc_table[i];
    k = 255 - k;
    k %= 255;//m_table的取值范围为 [0, 254]
    inverse_table[i] = table[k];
}
```

3.5.3 查表计算

见附 C 语言实现

4. 译码

4.1 高斯消元

首先举一个例子: 求解如下方程组:

$$\begin{cases} x - 2y + 3z = 6....... \\ 4x - 5y + 6z = 12...... \\ 7x - 8y + 10z = 21..... \end{cases}$$

我们手算一下这个方程组,过程如下:

1. ② - 4*①; ③ - 7*①, 得到如下式子:

$$\begin{cases} x-2y+3z=6.......\\ 0x+3y-6z=-12......@\\ 0x-6y-11z=-21..... \end{cases}$$

2. ②两边同除以3, 得到:

$$\begin{cases} x - 2y + 3z = 6............. \\ 0x + y - 2z = -4.......... \\ 0x - 6y - 11z = -21..... \end{cases}$$

3. ① - ②*(-2); ③-②*6, 得到:

4. 从③式得到 z=3,再代入②式得到 y=2,再代入到①式得到 x=1

5. 算法实现

5.1 系数矩阵寻找

保留

5.2 编码有限域计算

```
//加法
unsigned char uf_ywj_add(unsigned char a, unsigned char b)
{
    return a ^ b;
}

//乘法:
unsigned char uv_ywj_mul(unsigned char a, unsigned char b)
{
    if (a && b)
        return uv_ywj_Alogtable[(uv_ywj_Logtable[a] + uv_ywj_Logtable[b]) % 255];
    else return 0;
}
```

```
//除法实现
unsigned char uf_ywj_divi(unsigned char a, unsigned char b)
{
    int j;
    if (a == 0)
        return (0);
    if ((j = uv_ywj_Logtable[a] - uv_ywj_Logtable[b]) < 0)
        j += 255;
    return (uv_ywj_Alogtable[j]);
}
//逆元
unsigned char uf_ywj_inv(unsigned char in)
{
    /* 0 is self inverting */
    if (in == 0)
        return 0;
    else
        return uv_ywj_Alogtable[(255 - uv_ywj_Logtable[in])];
}</pre>
```

5.3 高斯消元

【见附录 c-code】